

线性与非线性回归模型的拟合与比较分析

杨帆

23375012@buaa.edu.cn

摘要

本次实验针对给定回归数据开展模型拟合与性能比较分析。实验数据存储于一个 Excel 文件中，其中表单1为训练集，表单2为测试集，每个表单均包含100个二维样本点。本文首先构建线性回归模型，并分别采用最小二乘法、梯度下降法和牛顿法进行参数估计；随后使用均方误差和决定系数作为指标，对模型在训练集与测试集上的表现进行综合评价。考虑到样本点整体变化趋势具有非线性特征，在线性模型分析基础上，进一步引入多项式回归和高斯基函数回归两类非线性方法进行拟合。实验结果表明，三种线性参数求解方法在同一模型设定下最终结果较为接近，其差异主要体现在求解机制与收敛效率上；而相较于线性模型，适当复杂度的非线性模型能够更有效地刻画数据变化规律，并获得更好的测试性能。实验说明，在回归任务中，模型形式是否适合数据规律是影响拟合效果的关键因素之一。

关键词： 线性回归；最小二乘法；梯度下降法；牛顿法；多项式回归；高斯基函数回归；模型比较。

一、问题背景与实验任务

回归分析的目标是根据已有样本学习输入变量与输出变量之间的对应关系，并据此对未知样本进行预测。线性回归由于形式简单、计算方便，是最基础的回归模型之一；但当数据关系较复杂时，简单线性模型便难以获得理想效果。因此，本实验不仅需要线性回归的参数求解方法，也需要进一步分析非线性模型对拟合性能的改进作用。

设训练样本记为

$$\mathcal{D}_{train} = \{(x_i, y_i)\}_{i=1}^{100} \quad (1.1)$$

测试样本记为

$$\mathcal{D}_{test} = \{(x_j, y_j)\}_{j=1}^{100} \quad (1.2)$$

本实验任务为学习回归函数

$$\hat{y} = f(x; \theta) \quad (1.3)$$

使预测值 $\hat{y}$ 尽可能接近真实值。为实现这一目标，本文首先构建线性回归模型，并分别采用最小二乘法、梯度下降法和牛顿法进行参数估计；随后引入多项式回归和高斯基函数回归两类非线性方法进行比较分析。模型性能主要通过均方误差和决定系数作为指标进行评价，并结合拟合曲线进行综合判断。

二、模型方法与评价指标

2.1 评价指标

为了全面评价模型在训练集和测试集上的性能，本文采用均方误差和决定系数作为评价指标。

均方误差定义为

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (2.1)$$

决定系数定义为

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (2.2)$$

其中， $\bar{y}$ 为真实值的平均值。一般而言，MSE越小，说明预测误差越小； R^2 越接近1，说明模型拟合效果越好^[1]。

2.2 线性回归模型法

本文首先采用线性回归模型进行拟合，其表达式为

$$\hat{y} = w_0 + w_1 x \quad (2.3)$$

其中， w_0 为截距， w_1 为回归系数^[3]。采用平方损失函数作为优化目标，有：

$$J(w_0, w_1) = \frac{1}{2N} \sum_{i=1}^N (w_0 + w_1 x_i - y_i)^2 \quad (2.4)$$

模型训练的目标就是找到合适的参数 w_0, w_1 ，使损失函数 $J(w_0, w_1)$ 最小。

2.2.1 最小二乘法

最小二乘法通过最小化所有样本残差平方和来估计参数^[3]。其优化目标可写为：

$$\min_{w_0, w_1} \sum_{i=1}^N (y_i - w_0 - w_1 x_i)^2 \quad (2.5)$$

设

$$\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i, \quad \bar{y} = \frac{1}{N} \sum_{i=1}^N y_i$$

则参数解析解为

$$w_1 = \frac{\sum_{i=1}^N (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^N (x_i - \bar{x})^2} \quad (2.6)$$

$$w_0 = \bar{y} - w_1 \bar{x} \quad (2.7)$$

最小二乘法的优点是可以直接得到解析解，计算简单、效率较高，适合本实验这类规模较小的数据问题。

2.2.2 梯度下降法

梯度下降法是一种迭代优化方法，其核心思想是沿着损失函数梯度的反方向不断更新参数，使目标函数逐步减小^[4]。

对损失函数 $J(w_0, w_1)$ 求偏导，可得参数更新公式

$$w_0^{(t+1)} = w_0^{(t)} - \eta \frac{1}{N} \sum_{i=1}^N (w_0^{(t)} + w_1^{(t)} x_i - y_i) \quad (2.8)$$

$$w_1^{(t+1)} = w_1^{(t)} - \eta \frac{1}{N} \sum_{i=1}^N (w_0^{(t)} + w_1^{(t)} x_i - y_i) x_i \quad (2.9)$$

其中， η 为学习率。梯度下降法不需要直接求解析解，适用于更一般的优化问题，但其效果受到学习率与迭代次数设置的影响。

2.2.3 牛顿法

牛顿法是一种利用二阶导数信息的优化方法。相较于梯度下降法，牛顿法不仅利用梯度，还利用目标函数在当前点附近的曲率信息，因此通常具有更快的收敛速度^[4]。

若记参数向量为

$$\mathbf{w} = \begin{bmatrix} w_0 \\ w_1 \end{bmatrix}$$

则牛顿法的更新公式为

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - \mathbf{H}^{-1} \nabla J(\mathbf{w}^{(t)}) \quad (2.10)$$

其中， $\nabla J(\mathbf{w}^{(t)})$ 表示梯度， $\mathbf{H}$ 表示Hessian矩阵。由于线性回归的平方损失函数是二次函数，因此牛顿法在本实验中通常可以较快收敛到最优解。

2.3 非线性回归模型法

2.3.1 多项式回归

为提高模型对复杂关系的表达能力，本文进一步采用多项式回归。其模型形式为

$$\hat{y} = w_0 + w_1x + w_2x^2 + \cdots + w_dx^d \quad (2.11)$$

其中， d 为多项式阶数。该模型通过引入高次项，使模型可以描述输入与输出之间的弯曲关系，因此特别适用于整体趋势平滑但明显偏离直线分布的数据。

选择多项式回归的原因在于：当样本散点图显示数据具有明显的整体弯曲趋势时，线性模型只能给出一条直线，难以反映这种非线性变化；而多项式回归能够通过增加模型阶数增强表达能力，更好地拟合全局趋势。同时，多项式回归仍然保持对参数的线性结构，便于求解和分析。

2.3.2 高斯基函数回归

除多项式回归外，本文还采用高斯基函数回归模型。其基本形式为

$$\phi_j(x) = \exp\left(-\frac{(x - \mu_j)^2}{2\sigma^2}\right) \quad (2.12)$$

在此基础上，回归模型可表示为

$$\hat{y} = w_0 + \sum_{j=1}^M w_j \phi_j(x) \quad (2.13)$$

其中，表示 μ_j 第 j 个基函数的中心， σ 表示基函数宽度， M 表示基函数个数^[2]。

选择高斯基函数回归的原因在于：若数据除了整体非线性趋势外，还包含局部起伏变化，则单一多项式模型有时会因为其全局性质而难以同时兼顾整体趋势与局部细节。高斯基函数具有局部响应特性，能够通过多个局部基函数的线性组合灵活逼近复杂曲线，因此适合拟合局部波动更明显的数据。

三、实验研究

3.1 实验步骤

- 1.读取训练集与测试集数据，并绘制样本散点图；
- 2.建立线性回归模型，分别采用最小二乘法、梯度下降法和牛顿法进行参数估计；

3.记录三种线性方法的最终参数收敛值，并计算训练集与测试集上的评价指标；

4.在观察线性模型拟合结果基础上，进一步引入多项式回归与高斯基函数回归；

5.比较不同非线性模型在测试集上的性能，并结合拟合曲线分析模型优劣。

3.2 数据分布可视化与初步观察

在建模之前，首先对训练集与测试集样本进行可视化，以便直观观察数据分布情况及其变化趋势。




图1：训练集与测试集散点图

从样本散点分布可以看出，数据整体存在一定变化趋势，但点的分布并未严格围绕一条直线展开，说明输入变量与输出变量之间并非简单的线性关系。因此，虽然可以先采用线性回归建立基准模型，但为了更准确地描述数据特征，故后续仍有必要尝试非线性回归方法。

3.3 线性回归模型实验结果

首先，分别采用最小二乘法、梯度下降法和牛顿法对线性回归模型进行求解，得到三种方法的最终参数值，如表1所示。

表1：线性回归模型参数计算结果

方法	ω_0	ω_1
最小二乘法	-0.648747	0.108947

梯度下降法	-0.648747	0.108947
牛顿法	-0.648747	0.108947

由表1可以看出，三种方法最终得到的参数完全一致，其中截距项 $\omega_0 = -0.648747$ ，一次项系数 $\omega_1 = 0.108947$ 。这说明在当前数据集和线性回归模型下，三种求解方法均成功收敛到相同的最优解。最小二乘法通过解析解直接求得参数；梯度下降法通过迭代优化逐步逼近最优解；牛顿法则利用二阶导数信息进行快速更新。虽然三者求解思路不同，但最终结果保持一致，说明程序实现正确，且该优化问题较为稳定。




图2：线性回归模型三种拟合方法结果图

为了进一步比较三种方法的拟合效果，计算其在训练集和测试集上的误差指标及决定系数，结果如表2所示。

表2：线性回归三种方法的性能比较表

方法	训练集MSE	测试集MSE	训练集 R^2	测试集 R^2
最小二乘法	0.613402	0.595043	0.141270	0.132873
梯度下降法	0.613402	0.595043	0.141270	0.132873
牛顿法	0.613402	0.595043	0.141270	0.132873

从表2可以看出，三种线性回归参数求解方法在训练集和测试集上的性能完全一致。这与表1中参数结果一致的结论相互印证，说明三种方法最终学习到了

同一个线性模型。不过，从具体指标来看，线性回归模型在训练集和测试集上的 R^2 均较低，说明该模型对数据变化规律的解释能力有限，难以充分刻画数据中的非线性变化趋势，这与前文对数据点分布规律的直观感受相吻合。

3.4 非线性回归模型实验结果

3.4.1 多项式回归模型实验结果

为提高模型对非线性关系的表达能力，本文在一元线性回归的基础上进一步构建了不同阶数的多项式回归模型，并对各模型在训练集与测试集上的表现进行了比较分析。多项式回归通过在原始输入变量的基础上增加高次项，从而增强模型对复杂函数关系的拟合能力。实验中分别选取2阶至13阶多项式模型，计算各模型的训练均方误差（MSE）、测试均方误差（MSE）、训练决定系数以及测试决定系数。

表3：不同阶数多项式回归模型结果

阶数	训练集MSE	测试集MSE	训练集 R^2	测试集 R^2
2	0.565418	0.534633	0.208446	0.220906
3	0.565298	0.536790	0.208614	0.217763
4	0.555905	0.541847	0.221763	0.210393
5	0.525176	0.515118	0.264783	0.249344
6	0.525173	0.515109	0.264786	0.249357
7	0.465070	0.463095	0.348927	0.325155
8	0.461389	0.461953	0.354080	0.326819
9	0.354109	0.387459	0.504266	0.435375
10	0.349728	0.383665	0.510400	0.440904
11	0.301304	0.339175	0.578190	0.505737
12	0.296801	0.342462	0.584495	0.500948
13	0.292073	0.358534	0.591113	0.477525

从表3可以看出，随着多项式阶数的增加，模型在训练集上的MSE整体呈下降趋势，而训练集上的 R^2 整体呈上升趋势。这表明随着模型复杂度提高，多项

式回归模型对训练样本的拟合能力不断增强。其原因在于，高阶多项式能够引入更多非线性项，从而更灵活地描述样本数据中的复杂变化规律。

然而，从测试集结果来看，模型性能并没有随着多项式阶数的增大而持续单调提升。当阶数较低时，模型的非线性表达能力不足，难以充分刻画数据规律；随着阶数提高，测试集MSE逐渐减小，测试集 R^2 逐渐增大，模型的泛化性能得到改善；但当阶数进一步增大后，测试性能的提升幅度减弱，甚至出现一定波动。这说明高阶多项式虽然能够更好地拟合训练数据，但也会提高模型复杂度，使其更容易对训练样本中的局部波动和噪声产生过度适应，从而带来过拟合风险^[5]。

结合表3可知，11阶多项式回归模型在测试集上取得了较优的综合表现。与其他阶数模型相比，该模型具有较低的测试集MSE和较高的测试集 R^2 ，并且在模型复杂度上仍保持在合理范围内。因此，本文将11阶多项式回归模型视为多项式回归方法中的最优模型，其拟合曲线如下：




图3：最优多项式回归模型拟合结果图

由图3可以看出，11阶多项式回归模型能够较好地贴合样本点的整体变化趋势，相比简单线性回归模型具有更强的非线性表达能力。

综上，多项式回归在本实验中明显优于线性回归，说明引入更多的非线性项能够有效提升模型对数据规律的表达能力。但模型阶数不宜无限制增加，应在拟合精度与泛化能力之间进行合理权衡。

3.4.2 高斯基函数回归模型实验结果

除多项式回归外，本文还采用高斯基函数回归模型对数据进行进一步的非线性拟合。高斯基函数回归通过多个局部高斯基函数的线性组合来逼近目标函数，具有较强的局部表示能力。与多项式回归不同，该模型的性能不仅与基函数个数有关，还与高斯基函数的带宽参数 σ 密切相关。基函数个数决定了模型的表示容量，而带宽参数决定了单个高斯基函数的作用范围：若 σ 过小，模型会更加敏感于局部细节，可能导致过拟合；若 σ 过大，模型过于平滑，又可能导致欠拟合。

为了更全面地评价高斯基函数回归模型的性能，本文分别取基函数个数 $M=5,10,15,20$ ，并在每种基函数个数下进一步比较不同带宽参数 σ 的影响。实验结果如下图所示。




图4：不同基函数个数下训练集MSE随 σ 变化折线图




图5: 不同基函数个数下训练集 R^2 随 σ 变化折线图

从训练集结果可以看出，随着基函数个数 m 的增加，训练集MSE整体下降，训练集 R^2 整体上升，说明模型对训练数据的拟合能力不断增强。当 $M=20$ 时，模型在训练集上的表现最好，并在 $\sigma=0.30$ 时取得最小训练MSE和最大训练 R^2 。这表明增大基函数个数和适当调整带宽参数能够提高模型对训练样本的拟合精度。




图6: 不同基函数个数下测试集MSE随 σ 变化折线图




图7：不同基函数个数下测试集 R^2 随 σ 变化折线图

与训练集相比，测试集结果更能反映模型的泛化性能。从图6和图7可以看出，随着基函数个数增加，模型测试性能整体改善；其中 $M=20$ 时曲线表现最好。当 σ 从较小值逐步增大时，测试集MSE逐渐减小、 R^2 逐渐增大，但当 σ 继续增大到0.30时，测试性能略有回落。这说明带宽过大会使模型过于平滑，从而影响其对测试数据的刻画能力。

综合训练集与测试集结果，虽然 $M=20, \sigma=0.30$ 的模型在训练集上表现最佳，但从测试集指标来看， $M=20, \sigma=0.25$ 的模型取得了最优综合性能。因此，本文将基函数个数为20、带宽参数为0.25 的高斯基函数回归模型作为最优模型。




图8：最优高斯基函数回归模型拟合结果图

由图8可以看出，最优高斯基函数回归模型能够较好地贴合样本点的整体变化趋势，同时在局部区域也具有较强的适应能力。相比线性回归和多项式回归，该模型在当前数据集上表现出更好的拟合效果和泛化能力。

3.5 不同回归模型的比较和分析

在完成线性回归、多项式回归和高斯基函数回归三类模型的实验后，我们可以从模型表达能力、测试集性能和参数复杂度三个方面进行比较分析。

首先，线性回归模型结构最简单，参数数量少，求解过程清晰，具有较强的可解释性。从实验结果看，最小二乘法、梯度下降法和牛顿法三种求解方式得到的模型参数和性能指标基本一致，说明在当前问题中，不同优化方法对最终结果影响较小。但由于线性回归只能描述变量之间的线性关系，当数据呈现明显非线性特征时，其拟合能力受到限制，因此整体预测效果相对一般。

其次，多项式回归通过引入高次项增强了模型的非线性表达能力，实验结果表明其整体性能优于线性回归。在不同阶数的比较中，11阶多项式回归模型取得了该类方法中的最佳测试结果，说明适当提高阶数有助于增强模型对数据规律的刻画能力。但多项式回归属于全局模型，阶数过高时容易出现局部波动，对模型阶数选择较为敏感，因此在提高拟合能力的同时，也需要兼顾模型复杂度和泛化性能。

相比之下，高斯基函数回归采用局部基函数构造模型，能够更灵活地刻画数据中的非线性变化。实验结果显示，随着基函数个数增加，模型的表达能力逐步增强；在带宽参数取值合适时，模型在测试集上的误差进一步减小。综合比较不同参数组合后，最优高斯基函数回归模型对应 $M=20$, $\sigma=0.25$ ，其测试集MSE最低、测试集 R^2 最高，表现出最好的泛化能力。

表4：三类回归模型最优结果对比表

模型	训练集MSE	测试集MSE	训练集 R^2	测试集 R^2	备注
线性回归	0.613402	0.595043	0.141270	0.132873	
多项式回归	0.301304	0.339175	0.578190	0.505737	11阶
高斯基函数回归	0.175416	0.253860	0.754426	0.630063	$m = 20$ $\sigma = 0.25$

四、结论

本文基于给定训练集和测试集数据，分别建立了线性回归、多项式回归和高斯基函数回归模型，并对不同模型的实验结果进行了比较。研究表明，线性回归模型能够反映数据的基本变化趋势，但由于模型形式较为简单，在处理非线性关系时效果有限。多项式回归通过引入高次项提升了非线性表达能力，其中11阶多项式回归模型取得了较优结果。高斯基函数回归进一步增强了模型对局部非线性特征的刻画能力，在多组参数比较中，基函数个数为20、带宽参数为0.25的模型表现最佳。

综合实验结果可以得出：对于本实验数据，非线性回归模型整体优于线性回归模型，而高斯基函数回归模型的综合性能最佳。这表明在处理复杂非线性数据时，选择具有更强表达能力的模型，并对关键参数进行合理调节，能够有效提高回归预测精度和模型泛化能力。此外，实验结果也表明，在回归建模过程中，模型复杂度并非越高越好，只有结合数据分布特征进行模型选择与参数调节，才能在拟合精度和泛化性能之间取得较优平衡。

五、参考文献

- [1] Hastie T, Tibshirani R, Friedman J. The Elements of Statistical Learning: Data Mining, Inference, and Prediction [M]. 2nd ed. New York: Springer, 2009.
- [2] Bishop C M. Pattern Recognition and Machine Learning [M]. New York: Springer, 2006.
- [3] Montgomery D C, Peck E A, Vining G G. Introduction to Linear Regression Analysis [M]. 5th ed. Hoboken: Wiley, 2012.
- [4] Nocedal J, Wright S J. Numerical Optimization [M]. 2nd ed. New York: Springer, 2006.
- [5] Murphy K P. Machine Learning: A Probabilistic Perspective [M]. Cambridge, MA: MIT Press, 2012.