

基于 3D Make-Moons 数据集的分类模型比较分析

杨帆

23375012@buaa.edu.cn

摘要

本文针对给定的 3D Make-Moons 数据集开展二分类模型比较研究。该数据集由程序生成，其两类样本在三维特征空间中呈现显著的非线性交错结构，因此适合作为研究不同分类器非线性判别能力的实验对象。根据题目要求，本文首先利用给定程序生成训练集，并进一步生成与训练集同分布的测试集。在建模之前，先对数据进行三维可视化与二维投影分析，以考察样本在特征空间中的几何分布特征，并据此判断问题的线性可分性与模型选择方向。随后，本文拟采用决策树（Decision Tree）、AdaBoost + Decision Trees 以及支持向量机（SVM）三类方法进行分类建模，其中 SVM 至少考虑三种不同核函数。为保证后续实验分析具有充分的理论依据，本文在实验实施之前系统阐述各类模型的基本原理、目标函数与适用特征，并给出相应评价指标。本文的研究重点在于解释：面对具有显著非线性几何结构的 3D Make-Moons 数据，不同模型为何会表现出不同的分类能力，以及模型性能差异与数据分布结构之间的内在联系。

关键词：3D Make-Moons；决策树；AdaBoost；支持向量机；核函数；分类性能比较。

一、引言

分类问题的基本任务是根据带标记样本学习输入空间到类别空间的映射关系，并利用所学习得到的判别函数对未知样本进行类别预测。模型的分类性能不仅取决于训练样本的规模与质量，而且与数据分布的几何结构以及模型本身的归纳偏置密切相关^[1]。对于近似线性可分的数据，线性分类器通常即可获得较好的预测性能；然而，对于存在复杂流形结构或明显非线性决策边界的数据，若模型缺乏足够的非线性表达能力，则往往难以取得理想的泛化结果。

本题所给数据并非来源于实际采样，而是由程序构造得到的 3D Make-Moons 数据。两类样本在三维空间中具有镜像、平移与交错分布特征，并叠加一定高斯

噪声,因此构成一个典型的非线性二分类问题。此类数据集具有明确的几何意义,能够较好地反映不同分类模型在处理非线性边界时的能力差异,因而适合作为模型比较实验的研究对象。

本文拟完成以下任务:首先依据题意生成训练集与测试集,在建模之前通过图形化手段分析数据分布特征;然后建立 Decision Tree、AdaBoost + Decision Trees 以及 SVM 模型,其中 SVM 模型采用多种核函数;最后在统一评价指标下对不同方法进行比较,并结合数据几何结构解释性能差异的原因。

需要特别指出的是,题目中函数 `make_moons_3d(n_samples, noise)` 的参数 `n_samples` 表示每一类的样本数,而非总样本数。因此,当训练集总样本数要求为 1000 时,应设定 `n_samples = 500`;当测试集总样本数要求为 500 时,应设定 `n_samples = 250`。这一点是保证实验设置与题意一致的前提。

二、数据生成机制与可视化分析

2.1 数据生成机制

设参数变量 $t \in [0, 2\pi]$, 则第一类样本由如下参数方程生成:

$$x = 1.5 \cos t, y = \sin t, z = \sin(2t) \quad (2.1)$$

第二类样本在第一类样本基础上经过镜像与平移变换得到:

$$x' = -x, y' = y - 1, z' = -z \quad (2.2)$$

设原始样本向量记为 $\mathbf{x} \in \mathcal{R}^3$, 则加入高斯噪声后的观测样本可表示为:

$$\tilde{\mathbf{x}} = \mathbf{x} + \varepsilon, \quad \varepsilon \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}) \quad (2.3)$$

由上述构造可知,两类样本并不是围绕某一线性超平面简单分离,而是在三维空间中形成相互交错的非线性流形结构。由于第二类样本相对于第一类样本在 x 轴与 z 轴方向上发生镜像变化,并在 y 轴方向上整体下移,因此两类样本之间的真实分界面应当是弯曲的非线性曲面,而非单一平面。

2.2 数据可视化分析

在正式进行模型训练之前,必须首先分析数据分布。原因在于,模型选择不脱离数据结构而孤立进行,而应建立在对样本几何特征、类别重叠情况以及潜在边界形态的初步认识之上。为此,本文分别绘制训练集与测试集的三维散点图,以及 XY、XZ、YZ 三个坐标平面上的二维投影图。




图 1 训练集样本三维散点图




图 2 测试集样本三维散点图

图 1 与图 2 分别给出了训练集和测试集在三维空间中的整体分布。由图中可以观察到，两类样本在空间中并未表现出明显的线性可分特征，而是呈现出相互包裹、交错延展的结构形态。这说明若使用线性分类模型，则其决策边界难以与样本分布的真实几何结构相匹配。




图 3 训练集样本三平面投影图




图 4 测试集样本三平面投影图

图 3 与图 4 分别展示了训练集和测试集在 XY、XZ 与 YZ 平面上的投影分布。从这些投影图可以进一步看出，不同类别在局部区域存在明显重叠，但这种重叠并非无规律随机混合，而是体现出一定连续性和弯曲性。这一现象表明：该问题的类别边界应更适合由具有非线性表达能力的模型来逼近，而不宜简单采用仅能学习线性超平面的分类器。

从图形化结果出发，可以对后续模型选择形成如下判断。首先，Decision Tree 由于能够通过递归划分特征空间来描述一定程度的非线性边界，因此应优于简单线性分类器；其次，AdaBoost 通过集成多棵弱树，可进一步提升边界表达能力，因此有望优于单棵 Decision Tree；最后，Support Vector Machine 中若采用非线性核函数，尤其是能够构造平滑非线性分界面的 Kernel Function，则理论上更适合处理该类 3D Make-Moons 数据。

因此，数据可视化并不仅仅是实验前的形式性步骤，而是后续模型分析与性能解释的重要依据。

三、模型方法

3.1 决策树 (Decision Tree)

Decision Tree 是一种通过递归划分特征空间实现分类的非参数监督学习方法。其基本思想是在每一个内部节点上选取最优划分特征及划分阈值,使得划分后子节点中的样本纯度尽可能提升,并最终在叶节点给出类别标记^[2]。

设当前节点对应的样本集合为 D , 类别集合为 $\{C_1, C_2, \dots, C_K\}$ 。若采用基尼指数作为划分准则, 则节点 D 的基尼指数定义为:

$$\text{Gini}(D) = 1 - \sum_{k=1}^K p_k^2 \quad (3.1)$$

其中, p_k 表示样本集合 D 中第 k 类样本所占比例。对于给定划分属性 A , 若样本集合 D 被划分为若干子集 D_v , 则划分后的加权基尼指数可写为:

$$\text{Gini}(D, A) = \sum_v \frac{|D_v|}{|D|} \text{Gini}(D_v) \quad (3.2)$$

Decision Tree 的训练过程本质上是在所有候选划分方案中寻找使 $\text{Gini}(D, A)$ 最小的划分方式。对于本题中的 3D Make-Moons 数据, Decision Tree 能够通过多次局部划分在一定程度上拟合非线性边界。然而, 标准 Decision Tree 的划分通常是轴对齐的, 因此其形成的决策边界往往呈现分段式、阶梯式特征。当真实边界较为平滑时, 单棵树通常难以以较低复杂度精确描述数据结构。

3.2 AdaBoost + Decision Trees

AdaBoost 是一种典型的 Boosting 集成方法, 其思想是通过迭代训练多个弱分类器, 并对其进行加权组合, 从而构造出性能更强的分类器^[3]。在本文中, AdaBoost 的基学习器选取为浅层 Decision Tree。

设训练集为:

$$\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N, \quad y_i \in \{-1, +1\}$$

在第 m 轮迭代中, AdaBoost 在样本权重分布 $w_i^{(m)}$ 下训练弱分类器 $G_m(x)$ 。其加权分类误差定义为:

$$e_m = \sum_{i=1}^N w_i^{(m)} I(G_m(\mathbf{x}_i) \neq y_i) \quad (3.3)$$

相应地，第 m 个弱分类器的组合系数为：

$$\alpha_m = \frac{1}{2} \ln \frac{1 - e_m}{e_m} \quad (3.4)$$

样本权重更新公式为：

$$w_i^{(m+1)} = \frac{w_i^{(m)} \exp(-\alpha_m y_i G_m(\mathbf{x}_i))}{Z_m} \quad (3.5)$$

其中， Z_m 为归一化因子。最终分类器可表示为：

$$F(\mathbf{x}) = \text{sign} \left(\sum_{m=1}^M \alpha_m G_m(\mathbf{x}) \right) \quad (3.6)$$

与单棵 Decision Tree 相比，AdaBoost 能够通过加权集成多个弱学习器逐步强化对难分类样本的关注，从而得到更复杂的决策边界。对于本题这种边界弯曲且带有一定噪声的数据，AdaBoost 理论上能够在表达能力和泛化能力之间取得更好的平衡。

3.3 支持向量机 (SVM)

SVM 的核心思想是在特征空间中构造最大间隔分离超平面，以提高模型的泛化能力。本文采用的支持向量机最大间隔思想及核方法基础可参见文献[4]。对于线性可分情形，设分类超平面为：

$$f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b = 0 \quad (3.7)$$

则硬间隔 SVM 的优化问题可表示为：

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 \quad (3.8)$$

约束条件为：

$$y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, N \quad (3.9)$$

对于线性不可分情况，引入松弛变量 ξ_i 后，软间隔优化问题写为：

$$\min_{\mathbf{w}, b, \xi} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N \xi_i \quad (3.10)$$

其约束条件为：

$$y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0 \quad (3.11)$$

当样本在原始空间中不可线性分离时，可通过 Kernel Function 将样本隐式映射到更高维特征空间。此时分类函数可写为：

$$f(\mathbf{x}) = \text{sign} \left(\sum_{i=1}^N \alpha_i y_i K(\mathbf{x}_i, \mathbf{x}) + b \right) \quad (3.12)$$

本文考虑以下四种 Kernel Function。

3.3.1 Linear Kernel

$$K(\mathbf{x}, \mathbf{z}) = \mathbf{x}^\top \mathbf{z} \quad (3.13)$$

Linear Kernel 不引入显式的非线性映射，因此仅适用于近似线性可分问题。在本题中，它主要作为基准模型，用于与非线性 Kernel Function 进行对照。

3.3.2 Polynomial Kernel

$$K(\mathbf{x}, \mathbf{z}) = (\gamma \mathbf{x}^\top \mathbf{z} + r)^d \quad (3.14)$$

其中， γ 为缩放系数， r 为常数项， d 为多项式阶数。Polynomial Kernel 能够表征较复杂的全局非线性关系，适用于整体边界具有弯曲结构的问题。

3.3.3 RBF Kernel

$$K(\mathbf{x}, \mathbf{z}) = \exp(-\gamma \|\mathbf{x} - \mathbf{z}\|^2) \quad (3.15)$$

RBF Kernel 具有较强的局部建模能力，能够形成平滑、灵活的非线性分类边界。对于 3D Make-Moons 这类具有明显弯曲结构的数据，RBF Kernel 理论上具有较强适应性。

3.3.4 Sigmoid Kernel

$$K(\mathbf{x}, \mathbf{z}) = \tanh(\gamma \mathbf{x}^\top \mathbf{z} + r) \quad (3.16)$$

Sigmoid Kernel 在形式上与神经网络激活函数存在一定相似性，但其性能通常对参数设置较为敏感，因此在实验中主要用作补充比较对象。

四、评价指标

为保证后续模型比较具有统一性，本文采用 Accuracy、Precision、Recall 和 F1-score 作为主要评价指标，并结合混淆矩阵进行辅助分析。

设真正例、真反例、假正例和假反例分别记为 TP、TN、FP、FN，则 Accuracy（准确度）定义为：

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (4.1)$$

Precision（精确度）定义为：

$$\text{Precision} = \frac{TP}{TP + FP} \quad (4.2)$$

Recall（召回率）定义为：

$$\text{Recall} = \frac{TP}{TP + FN} \quad (4.3)$$

F1-score 定义为：

$$F_1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (4.4)$$

由于本题中两类样本数量设置为均衡分布，因此上述指标能够较全面地反映分类器在整体正确率、正类识别能力以及精确率—召回率平衡方面的性能表现。

五、实验结果与分析

5.1 各模型分类性能比较

根据正式实验结果，本文统计了各模型在训练集与测试集上的准确率、精确率、召回率和 F1 分数，结果如表 1、表 2 所示。整体而言，测试集指标更能反映模型的泛化能力，因此本文后续分析将以测试集结果为主，并结合训练集指标辅助判断模型是否存在过拟合或欠拟合现象。

表 1：各模型在训练集上的分类性能比较

模型	准确率	精确率	召回率	F1 分数
AdaBoost + Decision Trees	0.996	0.998	0.994	0.996
Decision Tree	0.972	0.972	0.972	0.972
SVM (Polynomial Kernel)	0.988	0.984	0.992	0.988
SVM (RBF Kernel)	0.985	0.982	0.988	0.985
SVM (Linear Kernel)	0.676	0.677	0.672	0.675
SVM (Sigmoid Kernel)	0.553	0.552	0.564	0.558

表 2：各模型在测试集上的分类性能比较

模型	准确率	精确率	召回率	F1 分数
AdaBoost + Decision Trees	0.972	0.968	0.976	0.972
Decision Tree	0.940	0.944	0.936	0.940
SVM (Polynomial Kernel)	0.988	0.988	0.988	0.988
SVM (RBF Kernel)	0.986	0.980	0.992	0.986
SVM (Linear Kernel)	0.678	0.679	0.676	0.677
SVM (Sigmoid Kernel)	0.560	0.561	0.552	0.556

综合表 1 与表 2 来看，各模型的泛化特征存在明显差异。SVM（Polynomial Kernel）的训练集与测试集指标几乎一致，说明该模型在当前任务上不仅拟合能

力强，而且具有良好的泛化稳定性。SVM（RBF Kernel）也表现出类似特征，训练集与测试集结果高度一致，说明其决策边界与数据结构具有较高匹配度。相较之下，AdaBoost + Decision Trees 与 Decision Tree 的训练集性能均高于测试集性能，说明树模型虽然具有较强的拟合能力，但在当前任务上仍存在一定程度的过拟合倾向。另一方面，SVM（Linear Kernel）与 SVM（Sigmoid Kernel）在训练集与测试集上均表现较差，且两者差距较小，这表明其主要问题并非过拟合，而是模型表达能力不足，无法有效适应当前数据的非线性结构。

由表 2 可知，不同模型在该 3D Make-Moons 数据集上的性能差异较为显著。采用非线性核函数的支持向量机整体表现最佳，其中 SVM（Polynomial Kernel）在测试集上取得最高的综合性能，准确率、精确率、召回率和 F1 分数均达到 0.988；SVM（RBF Kernel）的测试集准确率为 0.986，与多项式核模型非常接近，同样表现出极强的分类能力。相比之下，AdaBoost + Decision Trees 的测试集准确率为 0.972，虽略低于两种高性能非线性核 SVM，但仍明显优于单棵 Decision Tree 的 0.9400。而 SVM（Linear Kernel）与 SVM（Sigmoid Kernel）的测试集准确率分别仅为 0.6780 与 0.5600，显著低于其他模型，说明这两类模型对于当前数据分布的适应性较差。

为了更直观地比较各模型在测试集上的综合表现，本文进一步绘制了测试集性能对比直方图，如图 5 所示。




图 5 测试集性能对比直方图

由图 5 可以更加清晰地看出，模型性能大致可分为三个层次。第一层次为 SVM（Polynomial Kernel）与 SVM（RBF Kernel），其四项指标均接近 1，表现显著优于其余模型；第二层次为 AdaBoost + Decision Trees 和 Decision Tree，说明树模型能够处理一定程度的非线性分类任务，但整体性能仍不及高质量的非线性核 SVM；第三层次为 SVM（Linear Kernel）与 SVM（Sigmoid Kernel），其各项指标明显偏低，表明这两种模型未能有效刻画数据的真实边界结构。

5.2 混淆矩阵的整体比较分析

为了进一步分析不同模型在测试集上的分类行为，本文将所有模型的测试集混淆矩阵统一绘制于图 6 中。与单纯比较准确率不同，混淆矩阵能够揭示模型在两类样本上的具体误分类分布，因此对于理解模型性能差异具有更强的解释力。




图 6 各模型混淆矩阵图

从图 6 可以看出，不同模型在误分类模式上呈现出明显差异。总体而言，性能优异的模型具有一个共同特征，即其混淆矩阵的主对角线元素远大于非对角线元素，说明绝大多数样本都被正确分类；而性能较差的模型则表现为非对角线元素显著增大，说明其无法建立与真实数据结构相匹配的有效决策边界。

具体来看，SVM（Polynomial Kernel）与 SVM（RBF Kernel）的混淆矩阵最接近理想状态。两者的误分类样本数都极少，且对 C0 与 C1 两类样本的识别都较为均衡，表明这两类模型不仅整体准确率高，而且分类边界稳定、鲁棒性较强。就细节而言，多项式核模型在两类样本上的误差分布最为对称，而 RBF 核模型在 C1 类样本上的召回能力略强，这与前述评价指标中的结果是一致的。

AdaBoost + Decision Trees 的混淆矩阵也表现出较强的判别能力，其主对角线元素明显占优，误分类样本数显著少于单棵 Decision Tree。这说明 Boosting 集成策略确实增强了模型对复杂边界附近样本的识别能力，使分类结果更加稳定。然而，与两种高性能非线性核 SVM 相比，其非对角线元素仍然略大，说明树模型集成虽然显著改善了边界表达能力，但在逼近平滑非线性边界时仍略逊一筹。

相比之下，Decision Tree 的混淆矩阵虽然仍以主对角线为主，但非对角线元素明显多于 AdaBoost 和两种高性能 SVM，这表明单棵树在当前任务中只能较粗略地逼近真实分类边界。由于其划分方式本质上是基于坐标轴的递归切分，所形成的边界往往呈现分段式和阶梯式特征，因此在处理当前数据所对应的平滑非线性结构时，会出现更多边界附近样本误分。

而 SVM（Linear Kernel）与 SVM（Sigmoid Kernel）的混淆矩阵则呈现出完全不同的特征：其非对角线元素数量显著增加，主对角线优势明显减弱，说明这两类模型在两类样本上的区分能力均较弱。其中，线性核模型在两类样本上的误分类近似对称，表明其学习到的线性分界面整体上无法适应当前数据的弯曲结构；Sigmoid 核模型的表现甚至进一步下降，说明在本实验设定下，其诱导的特征映射未能形成有效的判别边界。

5.3 不同模型性能差异的原因分析

结合表 1、图 5 以及图 6，可以进一步分析不同模型性能差异的根本原因。由前文数据可视化结果可知，该 3D Make-Moons 数据集在三维特征空间中呈现明显的交错与弯曲结构，并不满足简单线性可分条件。因此，模型性能的关键不在于是否能够完成局部分类，而在于其是否能够学习到与真实类别边界相匹配的非线性决策函数。

首先，SVM（Linear Kernel）表现较差的根本原因在于其只能学习线性超平面。对于当前数据，类别分界并非单一平面，而是具有明显弯曲特征的非线性曲

面，因此线性核模型的表达能力存在本质限制。其训练集与测试集性能均偏低，且差距较小，说明该模型并非过拟合，而是从模型层面就无法有效拟合数据结构。

其次，SVM（Sigmoid Kernel）在本实验中的表现最弱，说明该核函数形式与当前数据分布并不匹配。尽管 Sigmoid 核在形式上具有非线性特征，但从结果来看，其并未在当前任务中展现出有效的边界建模优势，反而表现出更明显的模型失配现象。

再次，Decision Tree 能够取得明显优于线性核与 Sigmoid 核 SVM 的结果，表明树模型具备一定非线性表达能力。然而，由于其空间划分方式通常是轴对齐的递归切分，因此生成的决策边界往往不够平滑。在面对当前这种具有连续弯曲结构的数据时，单棵树只能通过分段式方式近似边界，因而容易在局部区域产生误分类。同时，其训练集性能高于测试集性能，也说明其存在一定过拟合倾向。

在此基础上，AdaBoost + Decision Trees 通过集成多个弱树，显著提高了模型对复杂边界的刻画能力。与单棵树相比，其测试集指标和混淆矩阵都明显改善，说明 Boosting 机制能够通过逐轮关注难分类样本来提升整体判别效果。不过，从最终结果来看，该模型与最优的非线性核 SVM 之间仍存在一定差距，表明树集成虽然能够增强局部边界拟合能力，但在构造高度平滑的全局非线性边界方面仍不如核方法自然。

最后，SVM（Polynomial Kernel）与 SVM（RBF Kernel）之所以表现最佳，是因为它们能够通过核技巧在高维特征空间中构造非线性判别边界，从而更有效地适应当前数据的几何结构。其中，多项式核在本次实验中取得最高综合性能，说明当前数据边界不仅具有非线性，而且具有一定整体规律性；RBF 核则表现出极强的局部非线性建模能力，同样能够高质量地逼近真实边界。两者性能非常接近，表明它们都与当前任务的数据结构高度匹配。

综上所述，本实验结果表明：对于 3D Make-Moons 这类具有显著非线性几何结构的数据，模型优劣主要取决于其对非线性边界的表达方式。能够构造平滑、连续非线性分界面的模型通常表现最佳；仅依赖线性边界或阶梯式局部划分的模型则相对处于劣势。

六、结论

本文基于 3D Make-Moons 数据集比较了 Decision Tree、AdaBoost + Decision Trees 以及不同核函数下 SVM 的分类性能。实验结果表明，该任务本质上属于典型的非线性二分类问题，因此模型性能主要取决于其对非线性决策边界的表达能力。综合测试集指标与混淆矩阵分析可知，SVM（Polynomial Kernel）与 SVM（RBF Kernel）表现最佳，AdaBoost + Decision Trees 次之，单棵 Decision Tree 再次之，而 SVM（Linear Kernel）与 SVM（Sigmoid Kernel）表现较弱。由此可见，在具有明显非线性几何结构的数据上，能够构造平滑非线性分界面的模型通常更具优势。

七、参考文献

- [1] Bishop, C. M. Pattern Recognition and Machine Learning. Springer, 2006.
- [2] Breiman, L., Friedman, J. H., Olshen, R. A., & Stone, C. J. Classification and Regression Trees. Wadsworth International Group, 1984.
- [3] Freund, Y., & Schapire, R. E. A Decision-Theoretic Generalization of On-Line Learning and an Application to Boosting. Journal of Computer and System Sciences, 55(1), 119 – 139, 1997.
- [4] Cortes, C., & Vapnik, V. Support-vector networks. Machine Learning, 20, 273 – 297, 1995.