

基于单变量与多变量 LSTM 的 PM2.5 浓度预测比较研究

杨帆

23375012@buaa.edu.cn

摘要

本文针对空气质量时间序列中的 PM2.5 浓度预测问题，开展基于长短期记忆网络（LSTM）的单变量与多变量预测模型比较研究。所使用数据集包含逐小时记录的 PM2.5 浓度及多种气象变量，包括露点、温度、气压、风向、风速、降雪和降雨等信息，具有明显的时间相关性和多变量耦合特征。为保证建模过程的规范性，本文首先对数据进行时间顺序整理、缺失值处理、类别变量独热编码和归一化处理，并采用滑动窗口方法将原始时间序列转换为 LSTM 可接收的监督学习样本。

在模型构建方面，本文分别建立单变量 LSTM 模型和多变量 LSTM 模型。单变量模型仅使用历史 PM2.5 浓度作为输入，用于刻画污染浓度自身的时间依赖关系；多变量模型则在历史 PM2.5 浓度基础上进一步引入气象变量，以考察外部环境信息对预测精度的影响。实验中，两类模型采用相同的数据划分方式、网络结构、训练策略和评价指标，并通过 MAE、MSE、RMSE 和 R^2 对模型预测性能进行综合比较。

实验结果表明，两类 LSTM 模型均能够较好地跟踪 PM2.5 浓度的整体变化趋势，其中多变量 LSTM 模型在各项评价指标上均优于单变量 LSTM 模型，说明气象变量能够在历史污染浓度基础上为模型提供额外有效信息。进一步的 SHAP 可解释性分析表明，历史 PM2.5 浓度仍是影响预测结果的最主要因素，风向、露点、气压和温度等变量也对模型输出具有一定贡献；同时，模型主要依赖最近若干小时的历史信息完成下一小时预测。综上，本文结果说明，多变量时间序列建模能够在 PM2.5 短时预测任务中提升模型预测效果，并且 SHAP 分析能够为模型输入特征作用提供一定解释依据。

关键词：PM2.5 浓度预测；LSTM；多变量时间序列；空气质量预测；SHAP 可解释性分析

一、引言

空气质量预测是环境监测、城市管理与公共健康防护中的重要研究问题。其中，PM2.5 浓度作为衡量空气污染程度的重要指标之一，能够直接反映细颗粒物污染水平，对居民出行、污染预警和环境治理均具有实际意义。由于 PM2.5 浓度并非孤立变化，而是受到污染物累积、气象扩散条件以及短时环境扰动等多种因素共同影响，因此对其进行准确预测具有一定复杂性。

从数据形式看，空气质量数据通常按照时间顺序连续采集，具有典型的时间序列特征。当前时刻的 PM2.5 浓度往往与前若干小时的污染状态存在较强联系，表现出一定的短时惯性和滞后效应。同时，温度、气压、露点、风速、风向以及降雨降雪等气象条件也会影响污染物的扩散、沉降和累积过程。因此，PM2.5 浓度预测不仅是一个时间序列回归问题，也具有明显的多变量耦合特征。

本文将 PM2.5 预测任务形式化为：给定过去一段时间内的污染浓度及气象观测序列，预测下一小时的 PM2.5 浓度。设时刻 t 的多变量观测向量为 $\mathbf{x}_t$ ，输入时间窗口长度为 L ，则预测任务可表示为：

$$\hat{y}_{t+1} = f(\mathbf{x}_{t-L+1}, \mathbf{x}_{t-L+2}, \dots, \mathbf{x}_t)$$

其中， $\hat{y}_{t+1}$ 表示模型对下一小时 PM2.5 浓度的预测值， f 表示由模型学习得到的非线性映射关系。对于单变量预测模型，输入向量 $\mathbf{x}_t$ 仅包含 PM2.5 历史值；对于多变量预测模型，输入向量则同时包含 PM2.5 浓度及相关气象变量。通过在同一预测任务下比较两种输入方式，可以考察多变量信息是否能够为 PM2.5 浓度预测提供额外有效信息。

在时间序列建模方法中，长短期记忆网络 (Long Short-Term Memory, LSTM) 能够通过门控结构对历史信息进行选择性地保留与更新，较适合处理具有时间依赖关系的序列预测问题。相较于普通前馈神经网络，LSTM 不仅关注当前输入特征，还能够利用一段连续历史序列中的动态信息。因此，将 LSTM 应用于 PM2.5 浓度预测具有较强的合理性^[1]。

基于上述考虑，本文围绕空气质量数据集建立单变量多变量 LSTM 预测模型，并在统一实验条件下比较二者的预测性能。研究重点在于分析历史污染浓度本身能够提供多少预测信息，气象变量又能否在此基础上改善预测效果。通过这一比较，可以更清楚地认识多变量时间序列建模在空气质量预测任务中的作用。

二、数据集说明、可视化与预处理

2.1 数据集说明

本文所使用的数据集来自 Kaggle 平台的 Air Pollution Forecasting-LSTM Multivariate 数据集，该数据以小时为单位记录空气污染状况及同期气象条件^[2]。原始数据中包含日期时间、污染浓度、露点、温度、气压、风向、风速、累计降雪量和累计降雨量等信息。由于本文研究目标是预测下一小时的 PM2.5 浓度，因此将数据中的污染浓度字段作为目标变量，其余污染历史值及气象变量作为候选输入特征。本文使用的数据字段及其含义如表 1 所示。为便于后续建模，表中同时给出了本文在代码与实验分析中采用的统一字段记号。

表 1 数据字段说明

字段	含义	处理后记号
date	时间信息	datetime
pollution	PM2.5 浓度	pm2.5
dew	露点	DEWP
temp	温度	TEMP
press	气压	PRES
wnd_dir	风向	wnd_dir
wnd_spd	累计风速	Iws
snow	累计降雪量	Is
rain	累计降雨量	Ir

从数据结构看，该数据集是按照时间顺序排列的多变量观测序列。每一行样本既包含当前时刻的 PM2.5 浓度，也包含与该时刻对应的气象条件。因此，本文将建模为时间序列预测问题，即利用历史污染及气象信息预测未来时刻的 PM2.5 浓度。

2.2 数据可视化分析

在正式建模之前，首先对 PM2.5 原始时间序列进行可视化分析，以观察其整体变化趋势和波动特征。图 1 给出了数据集中 PM2.5 浓度随时间变化的曲线。




图 1 PM2.5 浓度原始时间序列

由图 1 可以看出,PM2.5 浓度在整个观测时间范围内呈现出明显的波动特征,既存在较长时间尺度上的整体变化,也存在局部时段内的剧烈突增和快速下降。这说明 PM2.5 序列并不是平稳不变的简单序列,而是具有较强动态变化特征的时间序列。

从局部变化看,PM2.5 浓度在相邻时刻之间通常具有一定连续性,即当前污染水平与前几个小时的污染状态密切相关;但在部分时段中,序列也会出现较尖锐的峰值变化,表明污染浓度可能受到突发气象条件或短时排放变化的影响。上述现象说明,在进行 PM2.5 预测时,一方面需要利用历史污染浓度中的时间依赖信息,另一方面也有必要引入气象变量来补充描述外部环境条件。

2.3 数据预处理方法

为了保证后续模型训练过程稳定,并减少无效数据对实验结果的影响,本文在建模前对数据进行了必要预处理。预处理过程主要包括时间顺序整理、缺失值处理、类别变量编码和数据归一化等步骤。上述处理的目的在于保持时间序列结构的完整性,降低异常数据对模型训练的影响,并使不同量纲的变量能够在统一尺度下参与模型学习。

2.3.1 时间顺序整理

由于本文研究对象为空气质量时间序列数据,因此在建模前首先将时间字段转换为标准的 `datetime` 格式,并按照时间先后顺序对样本进行排序。该步骤能够

保证后续训练集、验证集和测试集划分以及滑动窗口样本构造均遵循真实时间顺序。

时间序列预测的基本原则是利用过去信息预测未来。如果在建模前打乱样本顺序，可能使模型在训练阶段间接接触到未来时刻的数据分布，从而造成数据泄漏，导致测试结果偏高。因此，本文在整个实验过程中均保持数据的时间顺序，不采用随机打乱方式处理样本。

2.3.2 缺失值处理

缺失值处理是时间序列建模中的重要步骤。对于目标变量 $\text{pm}_{2.5}$ ，若其取值缺失，则对应样本无法提供有效监督信号，因此本文直接删除目标变量缺失的样本。对于露点、温度、气压、风速、降雪和降雨等数值型输入变量，本文采用前向填充与后向填充相结合的方式处理缺失值。

具体而言，前向填充利用当前缺失位置之前最近的有效观测值进行补全；若序列起始处存在无法通过前向填充补全的缺失值，则进一步采用后向填充方式补齐。该处理方式的依据在于，逐小时气象变量通常具有一定时间连续性，相邻时刻的气象条件不会发生完全无规律的剧烈跳变，因此使用相邻时刻信息进行填充具有一定合理性。

2.3.3 类别变量编码

数据中的风向变量 wnd_dir 属于类别变量，不具有连续数值意义。若直接将不同风向编码为整数输入模型，容易使模型误认为不同风向之间存在大小关系，从而引入不合理的顺序信息。为避免这一问题，本文采用独热编码方法对风向变量进行处理。

设风向变量共有 K 个类别，则每一种风向类别可被表示为一个 K 维二进制向量：

$$\mathbf{e}_k = (0, \dots, 0, 1, 0, \dots, 0), \quad k = 1, 2, \dots, K$$

其中，仅第 k 个位置取值为 1，其余位置均为 0。通过这种方式，模型可以区分不同风向类别，同时不会引入人为的大小关系。

2.3.4 数据归一化

由于不同特征的物理量纲和数值范围差异较大，若直接输入神经网络，可能

导致模型训练过程不稳定，甚至使某些数值范围较大的特征在训练过程中占据不合理优势。因此，本文采用 Min-Max 归一化方法对输入特征及目标变量进行缩放。

对于任一特征 x ，其归一化形式为：

$$x' = \frac{x - x_{min}}{x_{max} - x_{min}}$$

其中， x_{min} 和 x_{max} 分别表示该特征在训练集中的最小值和最大值。需要强调的是，归一化参数仅在训练集上拟合得到，随后用于验证集和测试集的计算。这样处理可以避免测试集信息参与训练过程，从而防止数据泄漏。

三、模型方法

3.1 LSTM 模型的基本原理

LSTM 是在循环神经网络基础上引入门控结构和细胞状态的一类序列建模方法^[3]。其基本计算过程并不是对每个时刻的输入进行孤立处理，而是在时间维度上递归更新状态变量。与普通 RNN 主要依赖隐藏状态传递信息不同，LSTM 同时维护隐藏状态 h_t 与细胞状态 C_t 。其中，隐藏状态主要用于当前时刻输出及下一时刻计算，细胞状态则承担跨时间步传递记忆信息的作用。LSTM 模型的结构图如下所示：




图 2 LSTM 模型结构示意图

如图 2 所示，LSTM 模型在时间维度上可展开为多个结构相同、参数共享的 LSTM 单元。每个时间步的 LSTM 单元接收当前输入 x_t 、上一时刻隐藏状态 h_{t-1} 和上一时刻细胞状态 C_{t-1} ，并输出当前隐藏状态 h_t 与当前细胞状态 C_t 。这种结构使得模型能够在序列处理中持续更新内部状态，而不是仅根据单个时刻输入进行预测。

从单个 LSTM 单元内部结构看，模型主要由遗忘门、输入门、候选记忆和输出门组成。遗忘门控制上一时刻细胞状态中保留的信息比例，输入门控制当前新信息写入细胞状态的程度，候选记忆提供当前时刻可能写入的新内容，输出门则决定细胞状态中哪些信息用于形成当前隐藏状态。通过这些门控结构，LSTM 将状态更新过程分解为保留历史信息、写入当前信息和输出当前表示三个环节，从而形成比普通循环单元更稳定的序列信息传递机制。

3.2 LSTM 单元计算过程

在时刻 t ，LSTM 单元的输入包括当前输入向量 x_t 、上一时刻隐藏状态 h_{t-1} 、以及上一时刻细胞状态 C_{t-1} 。为了同时利用当前输入与历史隐藏信息，LSTM 通常将 x_t 与 h_{t-1} 进行拼接，作为各个门控结构的共同输入：

$$z_t = [h_{t-1}, x_t]$$

遗忘门用于控制上一时刻细胞状态中有多少信息被保留到当前时刻，其计算公式为：

$$f_t = \sigma(W_f z_t + b_f)$$

其中， f_t 为遗忘门输出， W_f 和 b_f 分别表示遗忘门的权重矩阵与偏置项， $\sigma(\cdot)$ 为 Sigmoid 函数。由于 Sigmoid 函数输出范围位于 0 到 1 之间，因此遗忘门可以被理解为对历史记忆的保留比例。当 f_t 中某一分量接近 1 时，表示对应历史信息被较多保留；当其接近 0 时，则表示对应历史信息被较大程度遗忘。

输入门用于控制当前时刻的新信息写入细胞状态的程度，其计算公式为：

$$i_t = \sigma(W_i z_t + b_i)$$

其中， i_t 为输入门输出， W_i 和 b_i 分别表示输入门的权重矩阵与偏置项。输入门本身并不直接产生新的记忆内容，而是决定当前候选信息在多大程度上写入细胞状态。

候选记忆用于生成当前时刻可能写入细胞状态的新信息，其计算公式为：

$$\tilde{C}_t = \tanh(W_c z_t + b_c)$$

其中, $\tilde{C}_t$ 表示候选记忆状态, W_c 和 b_c 分别表示候选记忆对应的权重矩阵与偏置项, $\tanh(\cdot)$ 为双曲正切函数。候选记忆与输入门配合使用, 使模型能够根据当前输入和历史隐藏状态生成新的状态信息。

在遗忘门、输入门和候选记忆共同作用下, 当前时刻细胞状态的更新公式为:

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t$$

其中, $\odot$ 表示逐元素乘法。该公式表明, 当前细胞状态由两部分构成: 一部分来自上一时刻细胞状态中被遗忘门保留下来的信息, 另一部分来自当前候选记忆中被输入门允许写入的新信息。因此, LSTM 的状态更新不是简单覆盖历史状态, 而是在历史信息保留与当前信息写入之间进行动态调节。

输出门用于控制当前细胞状态中哪些信息被输出为当前隐藏状态, 其计算公式为:

$$o_t = \sigma(W_o z_t + b_o)$$

其中, o_t 为输出门输出, W_o 和 b_o 分别表示输出门的权重矩阵与偏置项。在输出门控制下, 当前隐藏状态 h_t 的计算公式为:

$$h_t = o_t \odot \tanh(C_t)$$

由上述计算过程可以看出, LSTM 通过遗忘门、输入门和输出门分别控制历史记忆保留、新信息写入和隐藏状态输出, 使模型能够在序列传播过程中有选择地更新内部状态。与普通循环结构相比, 这种机制使 LSTM 更适合处理具有连续变化和歷史依赖特征的时间序列数据。

3.3 本文预测模型构建

本文分别构建单变量 LSTM 模型和多变量 LSTM 模型。两类模型采用相同的网络结构, 区别主要体现在输入特征维数不同。单变量 LSTM 模型仅以历史 PM2.5 浓度作为输入, 用于刻画污染浓度自身的时间变化规律; 多变量 LSTM 模型则在历史 PM2.5 浓度基础上进一步加入露点、温度、气压、风向、风速、降雪和降雨等气象变量, 用于考察外部环境信息对预测精度的影响。

设样本数量为 N , 输入窗口长度为 L , 每个时间步的输入特征维数为 d , 则 LSTM 模型的输入张量可表示为:

$$X \in \mathbb{R}^{N \times L \times d}$$

模型通过 LSTM 层对历史序列进行递推计算，并利用最后时刻的隐藏状态作为该时间窗口的序列表示。随后，该隐藏状态经过输出层映射为下一时刻的 PM2.5 浓度预测值：

$$\hat{y}_{t+1} = W_y h_t + b_y$$

其中， $\hat{y}_{t+1}$ 表示模型对下一时刻 PM2.5 浓度的预测结果， W_y 和 b_y 分别为输出层权重和偏置。由于预测目标为连续数值，因此输出层仅对应一个标量预测结果。

在本文后续实验中，单变量模型与多变量模型采用相同的基本预测形式，二者差异仅体现在输入特征维数 d 的不同。单变量模型的输入仅包含历史 PM2.5 浓度，多变量模型则在此基础上进一步包含气象变量及风向编码特征。通过保持模型形式一致，可以使后续实验更集中地考察输入信息差异对预测性能的影响。

四、实验设计与实验步骤

4.1 数据划分、样本构造与训练参数

本文设置单变量 LSTM 和多变量 LSTM 两组实验。两组实验除输入特征不同外，其余数据划分方式、网络结构、训练参数和评价指标均保持一致。其中，单变量模型仅输入历史 PM2.5 浓度，多变量模型输入历史 PM2.5 浓度及相关气象变量。

由于本文任务属于时间序列预测问题，实验中按照时间先后顺序划分数据集，而不采用随机划分方式。训练集、验证集和测试集比例分别设置为 70%、15% 和 15%。其中，训练集用于模型参数学习，验证集用于监控训练过程并配合早停策略选择较优模型参数，测试集仅用于最终性能评价。

本文采用滑动窗口方法构造 LSTM 输入样本。设输入窗口长度为 L ，则每个样本由连续 L 个历史时间步组成，预测目标为下一时刻 PM2.5 浓度。实验中取 $L=24$ ，即利用过去 24 小时的历史观测信息预测下一小时 PM2.5 浓度。该设置能够覆盖一个完整昼夜周期，有利于模型学习污染浓度和气象变量在日内尺度上的变化规律。样本构造形式可表示为：

$$X_t = (x_{t-L+1}, x_{t-L+2}, \dots, x_t), \quad y_t = \text{PM2.5}_{t+1}$$

本文主要实验参数设置如表 2 所示。

表 2 实验主要参数设置

参数	设置值
输入窗口长度	24 小时
训练集比例	70%
验证集比例	15%
测试集比例	15%
LSTM 单元数	64
Dropout 比例	0.2
Batch size	64
最大训练轮数	30
Early Stopping	patience = 5

模型训练过程中采用 Adam 优化器更新参数^[4]，并以均方误差（MSE）作为损失函数。MSE 对较大的预测误差具有更强惩罚，因此适用于 PM2.5 浓度这类存在局部峰值波动的连续值预测任务。损失函数定义为：

$$\mathcal{L}_{\text{MSE}} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

其中， y_i 为真实值， $\hat{y}_i$ 为预测值， n 为样本数量。为降低过拟合风险，本文在训练过程中引入 Early Stopping 策略，当验证集损失在连续若干轮内不再下降时提前停止训练，并恢复验证集表现最优时的模型参数。

4.2 实验流程与评价指标

本实验首先完成数据预处理，包括时间排序、缺失值处理、风向变量独热编码和归一化处理；随后按照时间顺序划分训练集、验证集和测试集，并通过滑动窗口方法构造 LSTM 输入样本。在模型训练阶段，分别训练单变量 LSTM 和多变量 LSTM；在模型评价阶段，将预测值反归一化回原始 PM2.5 浓度尺度，并在测试集上计算评价指标。

本文采用 MAE、MSE、RMSE 和 R^2 四项指标评价模型性能。其中，MAE 用于反映平均绝对预测偏差，MSE 和 RMSE 用于衡量整体误差水平及较大误差影响， R^2 用于衡量模型对 PM2.5 浓度变化的整体拟合能力。一般而言，MAE、

MSE 和 RMSE 越小，说明预测误差越低； R^2 越接近 1，说明模型对目标变量波动的解释能力越强。本文同时采用上述指标，是为了从平均误差、大误差敏感性和整体拟合效果三个角度比较单变量模型与多变量模型的预测性能。

4.3 SHAP 可解释性分析设置

除预测精度比较外，本文进一步对多变量 LSTM 模型进行 SHAP 可解释性分析，以考察不同输入特征和不同历史时间步对模型预测结果的贡献。SHAP 方法基于 Shapley value 思想将模型输出分解为各输入特征的贡献值，从而能够在一定程度上解释复杂模型的预测依据^[5]。对于本文任务而言，SHAP 分析的目的不是替代预测指标，而是辅助说明多变量模型在利用 PM2.5 历史值之外，是否确实从气象变量中获得了有效预测信息。

为保证可解释性分析与主实验结果严格对应，本文在多变量 LSTM 模型训练完成后保存该轮训练得到的模型权重、输入特征名称、训练样本和测试样本。后续 SHAP 分析直接读取该已训练模型及其对应输入数据，不重新训练新的模型。这样处理能够保证 SHAP 解释对象与实验结果中的多变量 LSTM 模型完全一致，避免由于重新训练带来的模型权重差异影响解释结果。

在具体分析中，本文分别从三个角度展示 SHAP 结果：第一，基于平均绝对 SHAP 值计算全局特征重要性，用于判断整体上哪些输入变量对预测结果贡献较大；第二，对不同历史时间步的 SHAP 值进行汇总，用于分析模型更依赖近时刻信息还是较早时刻信息；第三，绘制特征—时间步联合热力图，用于观察不同变量在不同历史时刻的贡献分布。通过上述分析，可以从模型解释角度进一步验证多变量输入在 PM2.5 预测中的作用。

五、实验结果与分析

5.1 模型训练过程分析

在完成数据预处理、样本构造和参数设置后，本文分别对单变量 LSTM 模型和多变量 LSTM 模型进行训练。为观察模型训练过程是否稳定，本文绘制了两类模型在训练集和验证集上的损失变化曲线，如图 3 和图 4 所示。




图 3 单变量 LSTM 模型训练损失曲线




图 4 多变量 LSTM 模型训练损失曲线

由图 3 和图 4 可以看出，两类模型的训练损失和验证损失在训练初期均快速下降，随后逐渐趋于平稳，说明模型能够在训练过程中有效学习输入序列与 PM_{2.5} 预测目标之间的关系。从整体趋势看，训练过程未出现损失剧烈震荡或验证损失持续上升的现象，表明当前网络结构和训练参数设置较为稳定。

此外，两类模型的验证损失整体低于或接近训练损失，这一现象并不表示模

型异常。由于本文模型中加入了 Dropout 层，训练阶段会随机丢弃部分神经元连接，使训练过程相对更具扰动性；而验证阶段 Dropout 不再生效，因此验证损失可能低于训练损失。综合训练曲线可知，本文所采用的 LSTM 模型能够正常收敛，且未表现出明显过拟合现象。

5.2 单变量与多变量模型性能比较

为定量比较两类模型的预测效果，本文在测试集上分别计算 MAE、MSE、RMSE 和 R^2 四项评价指标，结果如表 3 所示。

表 3 两类 LSTM 模型测试集预测性能比较

模型	MAE	MSE	RMSE	R^2
单变量 LSTM	11.8198	514.7659	22.6885	0.9172
多变量 LSTM	11.5662	481.8626	21.9514	0.9225

由表 3 可以看出，多变量 LSTM 模型在各项指标上均优于单变量 LSTM 模型。这表明引入气象变量后，模型能够获得比单纯历史 PM2.5 序列更加充分的输入信息，从而提高下一小时 PM2.5 浓度的预测精度。

需要注意的是，多变量模型相对于单变量模型的提升幅度并非极端显著，但这一结果是合理的。对于一步预测任务而言，PM2.5 浓度本身通常具有较强的短时连续性，因此仅利用历史 PM2.5 序列已经能够获得较好的基础预测效果。在此基础上，气象变量更多起到补充和修正作用，使模型能够进一步刻画外部环境条件对污染浓度变化的影响。因此，多变量模型在已有较高拟合水平基础上的进一步提升，更能说明气象信息对预测任务具有实际辅助价值。

5.3 预测曲线对比分析

除评价指标外，本文进一步绘制测试集上真实值与预测值的对比曲线，以观察模型对 PM2.5 浓度变化趋势的拟合情况。图 5 和图 6 分别给出了单变量 LSTM 模型和多变量 LSTM 模型的预测结果。




图 5 单变量 LSTM 模型预测值与真实值对比图




图 6 多变量 LSTM 模型预测值与真实值对比图

由图 5 可以看出，单变量 LSTM 模型已经能够较好地跟踪 PM2.5 浓度的整体变化趋势。当真实值出现上升或下降时，预测曲线通常能够表现出相同方向的变化，说明历史 PM2.5 浓度本身包含较强的预测信息。这与前文定量指标中单变量模型已经取得较高 R^2 的结果是一致的。

与单变量模型相比，图 6 中的多变量 LSTM 模型预测曲线与真实曲线整体贴合程度更高。在多数波动区间内，多变量模型能够较好跟随真实 PM2.5 浓度的变化，尤其在部分局部转折位置，其预测结果相对更接近真实值。这说明温度、气压、露点、风向等气象变量能够为模型提供额外信息，使模型不仅依赖污染浓度自身的历史惯性，还能够利用外部环境条件对预测结果进行修正。

不过，从两幅预测曲线也可以看出，在个别突发峰值或剧烈波动位置，模型预测结果仍然存在一定偏差。这一现象说明 LSTM 虽然能够较好捕捉 PM2.5 序

列的主要变化趋势，但对于短时突发污染事件的精确预测仍有一定局限。造成该现象的原因可能在于：极端污染峰值通常受多种短时因素共同影响，而这些因素未必完全包含在当前输入变量中；同时，高峰样本在整体数据中占比相对有限，模型更容易学习整体变化规律，而对局部极端变化的拟合能力相对不足。

5.4 实验结果综合分析

综合表 3 及预测曲线结果可以看出，单变量 LSTM 模型与多变量 LSTM 模型均能够较好完成 PM2.5 一步预测任务。其中，单变量模型的较好表现说明 PM2.5 浓度序列本身具有明显的短时自相关性，历史污染浓度能够为下一小时预测提供重要信息。多变量模型在单变量模型基础上进一步降低预测误差，说明气象变量能够补充污染浓度历史序列中未能完全表达的信息。

从模型比较角度看，本文的重点并不在于说明多变量模型能够完全取代单变量模型，而在于说明当历史 PM2.5 浓度已经提供较强预测基础时，合理引入气象变量仍然能够带来稳定的性能提升。尤其是 MSE 和 RMSE 的下降表明，多变量输入对较大误差具有一定改善作用；而 R^2 的提高则说明模型对 PM2.5 整体波动的解释能力进一步增强。

因此，本文实验结果支持以下判断：在 PM2.5 浓度一步预测任务中，LSTM 模型能够有效利用历史序列信息进行短时预测；相较于仅使用历史 PM2.5 浓度的单变量模型，加入气象变量的多变量 LSTM 模型能够在多个评价指标上取得更优结果。

六、SHAP 可解释性分析

6.1 SHAP 方法及分析思路

在完成单变量与多变量 LSTM 模型的预测性能比较后，本文进一步对多变量 LSTM 模型进行 SHAP 可解释性分析。前文实验结果已经表明，多变量模型在所有指标上均优于单变量模型，但仅依靠评价指标仍难以说明模型主要利用了哪些输入信息。因此，本节通过 SHAP 方法从特征贡献角度分析多变量 LSTM 模型的预测依据。对于单个预测样本，SHAP 模型的输出可表示为：

$$f(x) = \phi_0 + \sum_{j=1}^M \phi_j$$

其中, $f(x)$ 表示模型对样本 x 的预测输出, ϕ_0 表示模型输出的基准值, ϕ_j 表示第 j 个输入特征对预测结果的贡献。若 $\phi_j > 0$, 说明该特征使预测值相对于基准值增大; 若 $\phi_j < 0$, 则说明该特征使预测值降低。

由于本文采用的是 LSTM 时间序列模型, 每个样本的输入不仅包含不同变量, 还包含不同历史时间步。因此, SHAP 分析不仅可以从特征维度考察哪些变量更重要, 也可以从时间维度考察模型更依赖哪些历史时刻的信息。本文分别从全局特征重要性、历史时间步重要性以及特征—时间联合贡献三个角度展开分析。

6.2 全局特征重要性分析

首先, 本文对各输入变量的 SHAP 绝对值在样本维度和时间维度上取平均, 以衡量不同变量对模型预测结果的总体贡献。对于第 j 个特征, 其全局重要性可表示为:

$$I_j = \frac{1}{NT} \sum_{n=1}^N \sum_{t=1}^T |\phi_{n,t,j}|$$

其中, N 表示参与解释的样本数量, T 表示输入时间窗口长度, $\phi_{n,t,j}$ 表示第 n 个样本在第 t 个历史时间步上第 j 个特征的 SHAP 值。 I_j 越大, 说明该特征在整体预测中对模型输出的影响越大。




图 7 SHAP 全局特征重要性图

由图 7 可以看出，历史 PM2.5 浓度在所有输入变量中具有最高的重要性，这说明多变量 LSTM 模型在进行下一小时预测时，仍然主要依赖污染浓度自身的历史信息。这一结果与时间序列预测任务的基本规律一致，即短时 PM2.5 浓度通常具有较强连续性，最近一段时间的污染水平对下一时刻预测具有直接影响。

除 PM2.5 外，风向相关变量和露点变量也表现出较高的重要性。其中，风向变量经过独热编码后以多个特征形式进入模型，其 SHAP 贡献相对靠前，说明不同风向状态会对模型预测结果产生一定影响。露点、气压和温度等气象变量也具有一定贡献，表明模型并未简单忽略外部气象信息，而是在 PM2.5 历史变化基础上进一步利用气象变量对预测结果进行修正。

相比之下，累计风速、降雪和降雨变量在本次实验中的全局重要性相对较低。这并不意味着这些变量在物理意义上完全无关，而是说明在当前数据、当前模型和当前一步预测任务下，它们对模型输出的平均贡献较小。

6.3 历史时间步重要性分析

除分析不同变量的重要性外，本文进一步考察不同历史时间步对模型预测结果的影响。具体而言，对每个历史时间步上的 SHAP 绝对值在样本维度和特征维度上取平均，从而得到模型对不同历史时刻的依赖程度。第 t 个历史时间步的重要性可表示为：

$$I_t = \frac{1}{Nd} \sum_{n=1}^N \sum_{j=1}^d |\phi_{n,t,j}|$$

其中， d 表示输入特征维数。该指标越大，说明对应历史时刻的信息对模型预测结果影响越明显。重要性图绘制如下：




图 8 SHAP 历史时间步重要性图

由图 8 可以看出，最接近预测时刻的历史时间步具有最高的重要性，其中 $t-1$ 时刻的贡献明显高于其他时间步；随后，随着历史时间距离预测时刻逐渐变远，时间步重要性整体呈下降趋势。这说明模型在进行下一小时预测时，最主要依赖最近几个小时的观测信息，而较早时刻的信息贡献相对较弱。

这一结果与 PM2.5 一步预测任务的特点相符合。由于预测目标是下一小时浓度，最近时刻的污染水平和气象状态通常包含最直接的预测信息，因此模型对近时刻输入更加敏感。同时，较早历史时刻虽然仍可能提供背景趋势信息，但其对下一小时预测的直接影响会逐渐减弱。由此可见，LSTM 模型在当前任务中主要学习到的是 PM2.5 浓度的短时动态关系。

6.4 特征—时间联合贡献分析

为了进一步观察不同变量在不同历史时刻上的作用，本文绘制了特征—时间步 SHAP 热力图。该图以横轴表示输入变量，以纵轴表示历史时间步，以颜色深浅表示对应“变量—时间步”组合的平均绝对 SHAP 值大小。相比单独的全局特征重要性或时间步重要性分析，特征—时间联合热力图能够更细致地反映模型在时间维度和变量维度上的信息利用方式。




图 9 特征—时间步 SHAP 热力图

由图 9 可以看出，模型贡献最集中的位置主要出现在靠近预测时刻的历史时间步，尤其是 $t-1$ 附近。其中， $t-1$ 时刻的 PM2.5 特征贡献最为突出，说明最近

一小时的污染浓度对下一小时预测具有主导作用。除 PM2.5 外，部分风向变量以及露点等气象变量也在近时刻表现出一定贡献，表明模型在短时预测中不仅利用污染浓度本身，也结合了当前环境条件对预测结果进行调整。

6.5 可解释性分析小结

综合上述 SHAP 分析可以看出，多变量 LSTM 模型的预测依据具有较明确的结构特征。首先，历史 PM2.5 浓度是影响模型预测结果的最主要变量，说明污染浓度自身的短时连续性仍是一步预测任务中的核心信息来源。其次，风向、露点、气压和温度等气象变量在模型中也具有一定贡献，说明多变量输入并非冗余信息，而是能够为预测结果提供补充。最后，时间步重要性分析表明，模型最依赖最近若干小时的历史信息，尤其是最接近预测时刻的输入。

因此，SHAP 结果从模型解释角度支持了前文实验结论：多变量 LSTM 模型相较于单变量模型具有更好的预测性能，并不是由于模型结构差异造成的，而是因为多变量输入为模型提供了额外有效信息。与此同时，SHAP 分析也表明，多变量信息的作用主要体现在对历史 PM2.5 预测基础的补充和修正，而不是完全改变模型的主要预测依据。

七、结论

本文围绕空气质量数据中的 PM2.5 浓度预测问题，建立了单变量 LSTM 与多变量 LSTM 两类模型，并在统一实验条件下比较了二者的预测性能。实验结果表明，LSTM 能够有效利用历史序列信息刻画 PM2.5 浓度的短时变化规律；在此基础上，引入气象变量后的多变量 LSTM 模型在 MAE 等指标上均取得更优结果，说明多变量输入能够为 PM2.5 预测提供有效补充信息。

通过预测曲线分析可以看出，两类模型均能较好跟踪 PM2.5 浓度的整体变化趋势，但在突发峰值和剧烈波动位置仍存在一定预测偏差。这表明 LSTM 对一般趋势具有较强拟合能力，但对短时极端变化的刻画仍受到输入变量、样本分布和模型结构等因素限制。

进一步的 SHAP 分析表明，多变量 LSTM 模型的预测主要依赖历史 PM2.5 浓度，尤其是最接近预测时刻的输入信息；同时，风向、露点、气压和温度等气象变量也对预测结果具有一定贡献。该结果从可解释性角度支持了多变量模型优

于单变量模型的实验结论，即气象信息的作用主要体现在对历史污染浓度预测基础的补充和修正。

总体来看，本文完成了从数据预处理、模型构建、实验比较到可解释性分析的完整流程。后续研究可进一步尝试不同预测步长、不同时间窗口长度以及 GRU、CNN-LSTM 或注意力机制等模型结构，以提高模型对极端污染波动和更长时间尺度变化的预测能力。

八、参考文献

- [1] Xayasouk, T., Lee, H., & Lee, G. Air Pollution Prediction Using Long Short-Term Memory (LSTM) and Deep Autoencoder (DAE) Models. *Sustainability*, 2020, 12(6): 2570. DOI: 10.3390/su12062570.
- [2] Roy, R. Air Pollution Forecasting - LSTM Multivariate. Kaggle Dataset.
- [3] Hochreiter, S., & Schmidhuber, J. Long Short-Term Memory. *Neural Computation*, 1997, 9(8): 1735–1780. DOI: 10.1162/neco.1997.9.8.1735.
- [4] Kingma, D.P., & Ba, J. Adam: A Method for Stochastic Optimization. *International Conference on Learning Representations*, 2015.
- [5] Lundberg, S.M., & Lee, S.-I. A Unified Approach to Interpreting Model Predictions. *Advances in Neural Information Processing Systems*, 2017.